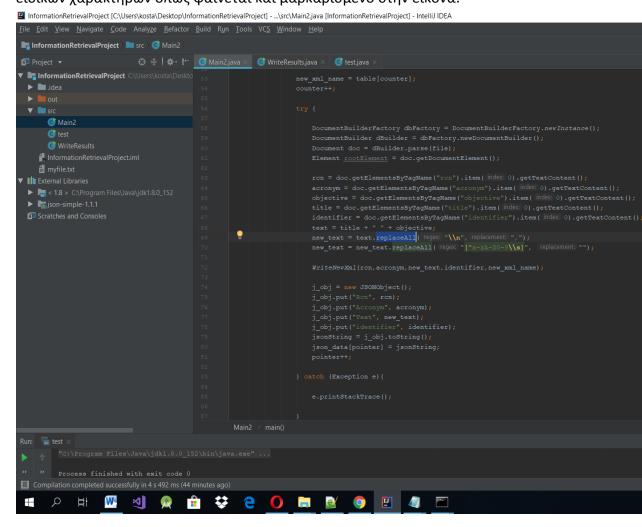
Κεχρής Κωνσταντίνος

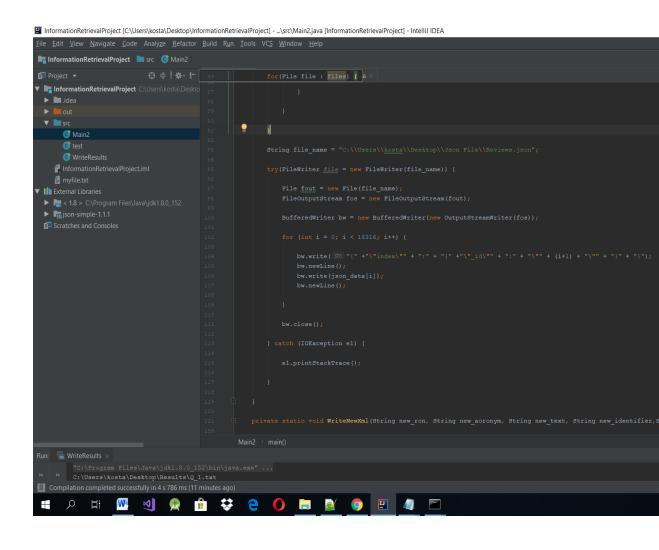
AM: 3150071

ΦΑΣΗ 1^η

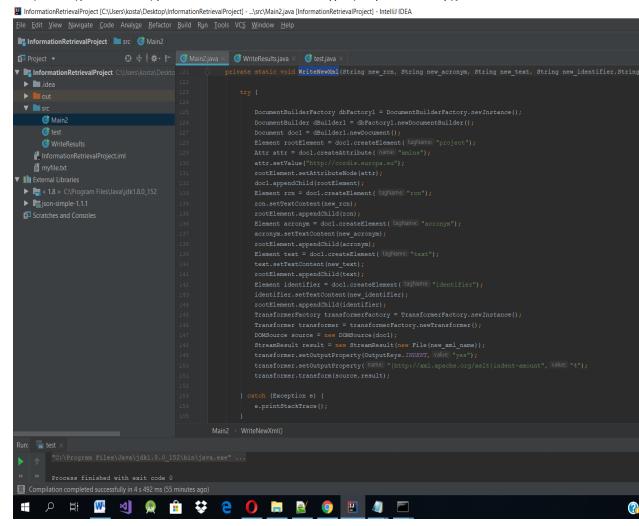
1) Ανάλυση του κώδικα: Αρχικά στην κλάση ΜΑΙΝ κάνω την απαραίτητη προεπεξεργασία των xml αρχείων. Διάβασμα τους με DOME όπως είδαμε στο αντίστοιχο εργαστήριο. Κατόπιν συνένωση του πεδίου title και objective σε νέο πεδίο text. Αξίζει να αναφερθεί ότι έγινε αφαίρεση ειδικών χαρακτήρων όπως φαίνεται και μαρκαρισμένο στην εικόνα.



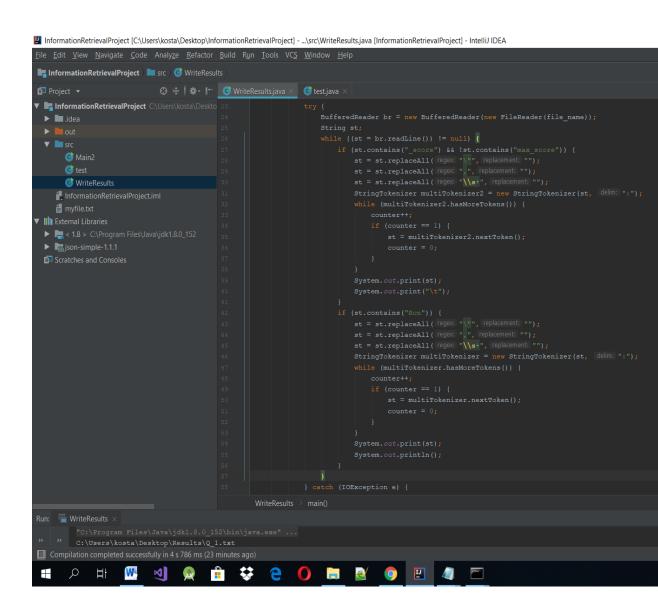
Έπειτα δημιουργώ αντικείνο τύπου JSONObject και του περνάω τα απαραίτητα attributes (rcn,text,Acronym,identifier). Στην συνέχεια περνάω όλη την πληροφορία του εκάστοτε JSONObject σε ένα String και αποθήκευση του στον πίνακα json_data για να το γράψουμε σε αρχείο.



Στην συνέχεια καλώ τη μέθοδο WriteNewXml όπου γράφουμε τα νέα αρχεία xml.



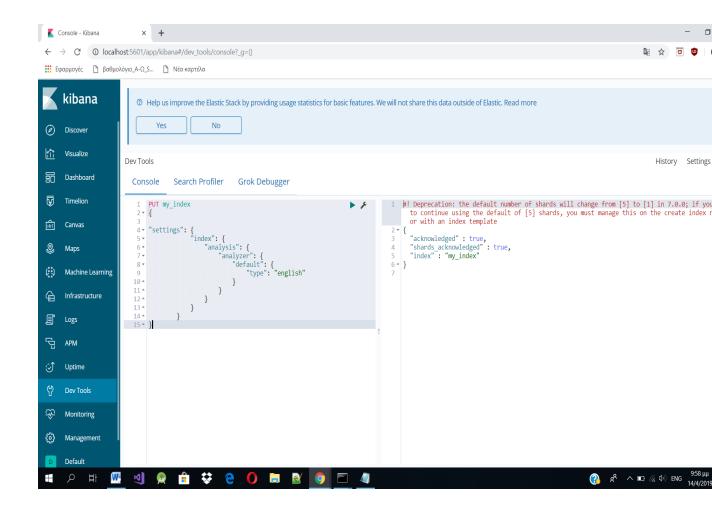
Η κλάση WriteResults χρησιμοποιείται ως εξής. Τα αποτελέσματα των queries που δώσαμε στο kibana τα πήραμε copy paste και τα βάλαμε σε 10 txt αρχεία που βρίσκονται στον φάκελο Results. Απο όλη την πληροφορία κρατάω το Rcn κάθε αρχείου και το Score του. Παίρνω με copy paste το αποτέλεσμα του WriteResults και το τοποθετώ σε νεό αρχείο το new_res. Και στην κλάση WriteResults έγινε αφαίρεση ειδικών χαρακτήρων όπως φαίνεται και παρακάτω στην εικόνα.



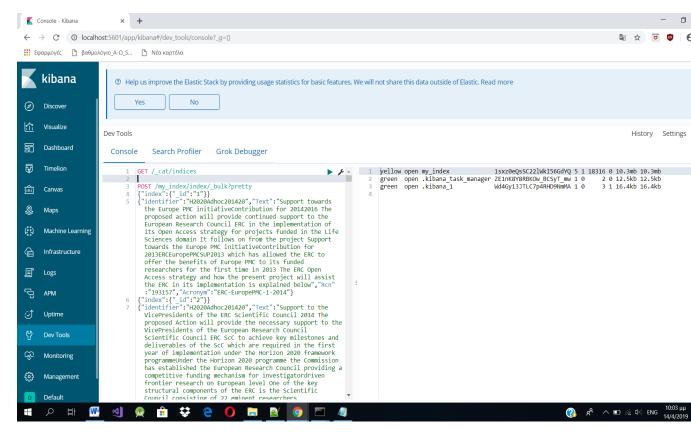
Επίσης έχουμε την κλάση Test όπου χρησιμοποιείται για να δημιουργήσουμε το τελικό αρχείο RESULTS προκειμένου να τρέξουμε το trec_eval. Τέλος χρησιμοποιώ την κλάση Test2 προκειμένου να καθαρίσω τα δέκα ερωτήματα από ειδικούς χαρακτήρες \n, \t κ.λ.π

2) Elasticsearch/kibana:

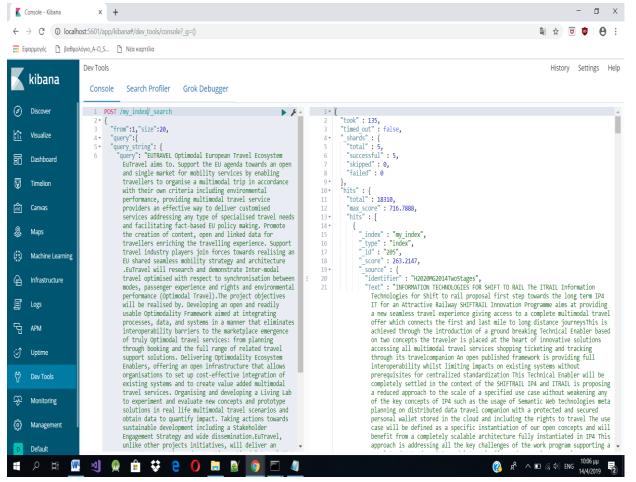
Αρχικά δημιουργία index με κατάλληλο analyzer. Χρησιμοποίησα τον English μιας και ανταποκρίνεται σε αυτά που ζητάει η άσκηση (stopword removal, transform to lower case, stemming).



Εισαγωγή json με _bulk?pretty



Έπειτα εκτέλεση ερωτημάτων:



3)Trec eval:

Τοποθέτησα τα δύο αρχεία Q_res και το Results στο ίδιο directory που είναι το trec_eval έτρεξα από cmd την εντολή:

trec_eval –q Q_res.txt RESULTS.txt τα αποτελέσματα του cmd τα πήρα copy paste και τα έβαλα σε αρχείο 3150071_results.txt.